

UNIVERSIDADE FEDERAL RURAL DO RIO DE JANEIRO
INSTITUTO MULTIDISCIPLINAR

BRENO SOUZA DIAS

Concordia MFT

Prof. Leandro Guimarães Marques Al-
vim, D.Sc.

Orientador

Prof. Nome do co-orientador, M.Sc.

Co-orientadora

Nova Iguaçu, Julho de 2025

Concordia MFT

Breno Souza Dias

Projeto Final de Curso submetido ao Departamento de Ciência da Computação do Instituto Multidisciplinar da Universidade Federal Rural do Rio de Janeiro como parte dos requisitos necessários para obtenção do grau de Bacharel em Ciência da Computação.

Apresentado por:

Breno Souza Dias

Aprovado por:

Prof. Leandro Guimarães Marques Alvim, D.Sc.

Prof. Nome do co-orientador, M.Sc.

Prof. Nome do participante banca 1, D.Sc.

Prof. Nome do participante banca 2, Ph.D.

NOVA IGUAÇU, RJ - BRASIL

Julho de 2025

Agradecimentos

Este trabalho é o reflexo de uma jornada que jamais trilhei sozinho, e por isso, agradeço profundamente a todos que fizeram parte dessa caminhada.

Aos meus pais, pilares da minha vida. À minha mãe, que com sua força silenciosa e gestos de amor me ensinou o que é ser forte mesmo quando tudo parece desabar, e a nunca deixar de acreditar. E ao meu pai, cuja resiliência e paciência mostraram que, mesmo diante dos maiores obstáculos, é possível seguir em frente com dignidade e coragem. A história de vocês me inspira todos os dias a lutar pelos meus sonhos.

Ao meu irmão mais novo, a quem sempre desejei mostrar que é possível chegar lá. Cada esforço meu teve, em parte, o objetivo de servir como exemplo para você. Espero que este trabalho possa representar a mensagem que sempre quis te passar: nunca duvide do que você pode alcançar.

À minha namorada, companheira de dias bons e ruins, que esteve ao meu lado em cada etapa dessa jornada. Sua presença e carinho foram fundamentais para que eu encontrasse equilíbrio mesmo nos momentos de maior pressão.

Aos meus amigos e amigas, por cada conversa, incentivo e distração necessária. Vocês tornaram essa trajetória mais leve e significativa.

Aos meus colegas de faculdade, por compartilharem comigo aprendizados, dúvidas e conquistas. E aos meus professores, por dedicarem tempo, conhecimento e entusiasmo ao nosso crescimento. Levo comigo muito mais do que conteúdos acadêmicos – levo inspiração.

A cada um de vocês, minha mais sincera gratidão.

**"Somos o que repetidamente fazemos. A excelência, portanto,
não é um feito, mas um hábito."**

Aristóteles

RESUMO
Concordia MFT
Breno Souza Dias
Julho/2025

Orientador: Leandro Guimarães Marques Alvim, D.Sc.

A acessibilidade urbana ainda representa um desafio em diversas cidades brasileiras, especialmente para pessoas cadeirantes. Este trabalho propõe uma abordagem baseada em modelos multimodais de inteligência artificial, para detectar e classificar elementos de acessibilidade em imagens de fachadas urbanas extraídas do Google Street View. Utilizando os critérios técnicos da norma brasileira NBR 9050/2020, o sistema identifica rampas, corrimãos, pisos táteis e demais estruturas acessíveis, classificando os locais como acessíveis, parcialmente acessíveis ou não acessíveis. Diferente de soluções internacionais da literatura, esta proposta é voltada ao contexto brasileiro e adota rigor técnico normativo nacional, promovendo avaliações mais alinhadas com a realidade urbana local. A integração de grandes modelos de linguagem (LLMs) à análise visual também permite maior precisão, escalabilidade e padronização na identificação de barreiras arquitetônicas.

Este experimento emprega os modelos de linguagem gpt-4o e Gemini 2.5 Flash para a tarefa de classificação. Será realizada uma análise comparativa com o objetivo de avaliar o desempenho de ambas as inteligências artificiais, bem como verificar a viabilidade da aplicação de sistemas de IA na classificação da acessibilidade em ambientes urbanos.

Palavras-chave: acessibilidade urbana. inteligência artificial. modelos multimodais. NBR 9050. Google Street View.

ABSTRACT
Concordia MFT
Breno Souza Dias
Julho/2025

Advisor: Leandro Guimarães Marques Alvim, D.Sc.

Urban accessibility still represents a challenge in several Brazilian cities, especially for wheelchair users. This work proposes an approach based on multimodal artificial intelligence models, to detect and classify accessibility elements in images of urban facades extracted from Google Street View. Using the technical criteria of the Brazilian standard NBR 9050/2020, the system identifies ramps, handrails, tactile floors, and other accessible structures, classifying the locations as accessible, partially accessible, or not accessible. Unlike international solutions in the literature, this proposal is external to the Brazilian context and adopts technical rigor from national standards, promoting assessments that are more in line with the local urban reality. The integration of large language models (LLMs) into visual analysis also allows for greater accuracy, scalability, and standardization in the identification of architectural barriers.

This experiment uses the gpt-4o and Gemini language models for the classification task. A comparative analysis will be conducted to evaluate the performance of both AIs, as well as to verify the feasibility of applying AI systems to accessibility classification in urban environments.

Keywords: *urban accessibility. artificial intelligence. multimodal models. NBR 9050. Google Street View.*

Lista de Figuras

3.1	Agrupamento moral das personas por K-Means e PCA	21
3.2	Intensidade dos Fundamentos Morais por Persona	22

Lista de Tabelas

List of Algorithms

Lista de Tabelas

Lista de Abreviaturas

AGs	Agentes Generativos
MBAG	Modelos Baseados em Agentes Generativos
GM	Game Master
LLMs	Large Language Models
MFQ	Moral Foundation Questionnaire
MFT	Moral Foundation Theory
PLMs	Pre-trained Language Models
PLN	Processamento de Linguagem Natural
RPG	Role-Playing Game
IA	Inteligência Artificial
MBA	Modelos Baseados em Agentes
API	Application Programming Interface

Lista de Símbolos

Sumário

Agradecimentos	i
Resumo	iii
Abstract	iv
Lista de Figuras	v
Lista de Tabelas	vi
Lista de Tabelas	vii
Lista de Abreviaturas	ix
Lista de Símbolos	x
1 Introdução	1
1.1 Contextualização	1
1.2 Objetivos Gerais	3
1.3 Objetivos Específicos	3
1.4 Contribuições	4

1.5	Resumo dos Resultados	5
1.6	Organização do Texto	5
2	Referencial Teórico	7
2.1	Simulação	7
2.2	Ambiente de Simulação de Agentes	9
2.3	O que é são os Fundamentos Morais?	10
2.4	Como ocorre a difusão de informações nas redes sociais?	13
2.5	A influência da moralidade na difusão de informações nas redes sociais	14
2.6	Concordia	16
3	Metodologia	20
3.1	Dataset	20
3.2	Experimento	22
4	Resultados	24
4.1	Análise	24
5	Conclusões	26
5.1	Problema	26
5.2	Proposta	27
5.3	Resumo dos resultados	27
5.4	Contribuições	27
5.5	Direções Futuras	27
	Referências	28

Capítulo 1

Introdução

1.1 Contextualização

A moralidade, compreendida como o conjunto de princípios que distinguem o certo do errado, governa as interações humanas e molda atitudes, crenças e julgamentos em diversas culturas (GUO; MOKHBERIAN; LERMAN, 2023). Seu papel é central em fenômenos sociais de grande impacto, como a formação de ideologias partidárias, estratégias de comunicação política e até a eclosão de violência em cenários de protesto (GRAHAM; HAIDT; NOSEK, 2009). Diante de sua relevância, a operacionalização computacional da moralidade emergiu como um campo de pesquisa fundamental, especialmente com os recentes avanços em Processamento de Linguagem Natural (PLN) e nos Large Language Models (LLMs).

Um dos pilares teóricos mais influentes para a análise computacional da moralidade é a Moral Foundation Theory (MFT), que caracteriza o raciocínio moral humano em cinco dimensões principais: Cuidado/Dano (Care/Harm), Justiça/Trapaça (Fairness/Cheating), Lealdade/Traição (Loyalty/Betrayal), Autoridade/Subversão (Authority/Subversion) e Santidade/Degradação (Sanctity/Degradation) (HAIDT; JOSEPH, 2004). Inicialmente, os estudos dependiam de questionários e cenários hipotéticos para quantificar essas dimensões. Contudo, o avanço dos Pre-trained Language Models (PLMs) permitiu escalar a inferência de fundamentos morais para grandes volumes de texto, como notícias e publicações em redes sociais, abrindo novas

fronteiras para a investigação do papel da moralidade na sociedade. Atualmente, o MFT vem sendo utilizado como forma de avaliar traços de moralidade em grandes modelos de linguagem.

O advento dos LLMs impulsionou uma nova era na simulação do comportamento humano por meio de modelos baseados em agentes (ADORNETTO et al., 2024). Agentes Generativos (AGs), equipados com LLMs, são capazes de simular comportamentos humanos verossímeis, aproveitando o vasto conhecimento sobre normas sociais, valores morais e padrões de comportamento herdados de seus massivos dados de treinamento. Diferentemente de abordagens tradicionais que dependem de regras predefinidas ou modelos matemáticos, esses agentes utilizam a linguagem natural para interagir, perceber, memorizar e tomar decisões de forma dinâmica e adaptativa, tornando as simulações mais realistas e flexíveis.

A hipótese é que os LLMs modernos, treinados em vastos volumes de cultura humana, são capazes de fornecer respostas realistas a essas perguntas quando recebem o contexto histórico de um agente específico. Essa capacidade de replicar a complexidade humana abre caminho para novos experimentos, permitindo investigar fenômenos como a difusão de influência em redes sociais (ZHANG et al., 2025), a dinâmica de opiniões (CHUANG et al., 2023) e até o surgimento de normas sociais em comunidades simuladas.

Apesar de sua alta capacidade de simular o comportamento humano, os LLMs carregam tendências presentes nos vastos dados da internet com os quais são treinados, o que pode interferir nos resultados das simulações e propagar vieses indesejados. No estudo (ABDULHAI et al., 2024), no qual várias LLMs responderam ao Moral Foundation Questionnaire (MFQ), foi observado que os modelos, quando não recebem um direcionamento específico, tendem a exibir um comportamento moral mais semelhante ao de pessoas com posicionamentos conservadores. Pessoas com orientação conservadora tendem a equilibrar os cinco fundamentos morais (Cuidado, Justiça, Lealdade, Autoridade e Santidade), enquanto pessoas com orientação liberal nos costumes dão ênfase maior aos fundamentos de Cuidado/Dano e Justiça/Trapaça (GRAHAM; HAIDT; NOSEK, 2009).

Uma das principais formas de criar um ambiente onde se possa criar agentes e simular interações, é usando *frameworks* como o Concordia (VEZHNEVETS et al., 2023), ferramenta que facilita a construção de Modelos Baseados em Agentes Generativos (MBAG), onde múltiplos agentes, cada um com sua personalidade, descrição e histórico de experiências, coexistem em um ambiente simulado. A dinâmica dessas simulações é gerenciada por um agente especial conhecido como Game Master (GM), um conceito inspirado em jogos de *Role-Playing Game (RPG)* de mesa. O GM tem a responsabilidade fundamental de simular o ambiente, apresentando aos agentes o estado atual do mundo, a situação global em que se encontram e os eventos que resultam de suas ações. Além disso, o GM media as interações entre os agentes, traduzindo suas intenções declaradas em linguagem natural para ações concretas e resolvendo conflitos, garantindo assim a consistência e o andamento da simulação.

1.2 Objetivos Gerais

Este trabalho tem como objetivo analisar o processo de difusão de informações em redes sociais, utilizando a biblioteca Concordia para a criação de um ambiente de simulação baseado em agentes generativos.

Os agentes serão desenvolvidos com personas fundamentadas na MFT, permitindo representar diferentes traços de personalidade, experiências e orientações políticas. Dessa forma, busca-se compor um ecossistema social artificial que reflita, de maneira aproximada, as dinâmicas e interações observadas em plataformas de redes sociais reais.

1.3 Objetivos Específicos

- Implementar um ambiente de simulação utilizando a biblioteca Concordia, configurando a interação entre os agentes e os mecanismos de propagação da informação.
- Executar experimentos que simulem distintos cenários de difusão, variando o

tipo de informação, a composição moral dos agentes e o nível de polarização da rede.

- Coletar e analisar os dados das simulações, identificando padrões de propagação, influência moral e formação de grupos ou bolhas informacionais.
- Comparar os resultados obtidos com estudos teóricos e empíricos sobre comportamento informacional em redes reais, avaliando a validade e as limitações do modelo proposto.

1.4 Contribuições

Nesta seção, apresentamos um resumo das principais contribuições deste trabalho, que abrangem desde a modelagem teórica até a análise empírica e a disponibilização do código-fonte e o modelo de simulação são oferecidos para futuras pesquisas.

(i) *Uma Abordagem Interdisciplinar para Modelagem de Agentes*

Propomos um modelo conceitual que traduz os cinco eixos da Teoria dos Fundamentos Morais em parâmetros e heurísticas comportamentais para agentes computacionais. Esta contribuição estabelece uma ponte metodológica entre a psicologia social e a simulação de agentes, permitindo a criação de personas digitais com diferentes vieses morais.

(ii) *Implementação de um Ambiente de Simulação com Concordia*

Desenvolvemos uma metodologia prática para implementar estes agentes com perfis morais distintos utilizando a biblioteca Concordia. O trabalho serve como um caso de uso e um guia para a aplicação desta ferramenta em pesquisas de ciências sociais computacionais, detalhando a arquitetura e a configuração do ambiente para simular a interação e a troca de informações.

(iii) *Análise Experimental sobre a Dinâmica da Informação*

Por meio de simulações em ambientes com diferentes composições de agentes (moralmente homogêneos e heterogêneos), conduzimos uma análise empírica

sobre como a diversidade de fundamentos morais afeta a velocidade, o alcance e a fidelidade da difusão de informações. Os resultados oferecem percepções quantitativas sobre a formação de bolhas informacionais e a dinâmica da polarização.

(iv) *Disponibilização de Código-Fonte e Modelo*

O código-fonte do ambiente de simulação, os perfis dos agentes e os cenários experimentais foram documentados e serão disponibilizados publicamente, fomentando a reprodutibilidade da pesquisa e servindo como uma base sólida para trabalhos futuros que explorem dinâmicas sociais complexas.

1.5 Resumo dos Resultados

TODO

1.6 Organização do Texto

O capítulo 2 aborda a fundamentação teórica, explorando os conceitos-chave da Teoria dos Fundamentos Morais e os princípios de simulação de agentes. Além disso, são descritas as ferramentas utilizadas, com foco na biblioteca Concordia, e apresentados os trabalhos relacionados.

O capítulo 3 apresenta a proposta deste trabalho, que investiga a difusão de informações em ambientes de agentes com diferentes perfis morais. Detalhamos a metodologia para a construção das personas dos agentes e a configuração do ambiente de simulação.

O capítulo 4 descreve os experimentos realizados neste estudo. São apresentados os cenários de teste, as métricas de avaliação e a execução das simulações para coleta de dados sobre o fluxo de informação.

O capítulo 5 apresenta a análise e discussão dos resultados obtidos. Por fim, são expostas as conclusões do trabalho, as limitações encontradas e as sugestões para

pesquisas futuras.

Capítulo 2

Referencial Teórico

2.1 Simulação

A simulação pode ser definida formalmente como a imitação da operação de um processo ou sistema do mundo real ao longo do tempo, envolvendo a geração de um histórico artificial para inferir características operacionais do sistema em estudo (BANKS et al., 2010). Ao substituir soluções analíticas dedutivas por métodos numéricos computacionais, a simulação permite a avaliação de cenários hipotéticos e a predição do comportamento de sistemas, sejam eles discretos, contínuos ou híbridos, sem a necessidade de interferir no sistema físico real e evitando os custos da experimentação direta.

Uma simulação pode ser determinística, onde os mesmos parâmetros de entrada geraram sempre o mesmo resultado como saída, para situações específicas e de menor escopo geralmente é o suficiente. Por outro lado simulações mais ambiciosas e que buscam representar fenômenos físicos com o decorrer do tempo, ou até mesmo o comportamento humano, tendem a ser estocásticas, contendo assim uma variável de aleatoriedade que ajuda a criar um cenário fidedigno com a mundo real (ADORNETTO et al., 2024).

Nos últimos anos tem se tornado cada vez mais comum o uso de inteligência artificial e aprendizado de máquina nas simulações. Esta tendência é impulsionada

pela disponibilidade de grandes volumes de dados, conceito conhecido como *Big Data*, e pelo aumento do poder computacional, que viabilizam novas possibilidades para a análise, predição e otimização de sistemas em engenharia, física e ciência dos materiais (KRZYWAŃSKI et al., 2024). A integração de algoritmos de inteligência artificial com métodos computacionais tradicionais, como a Análise de Elementos Finitos (BADARINATH; CHIERICHETTI; KAKHKI, 2021) e a Dinâmica dos Fluidos Computacional (RAHMAN et al., 2023), métodos já consagrados em simulações, permite a execução de análises paralelas e a abordagem de problemas interdisciplinares sofisticados que seriam computacionalmente inviáveis utilizando apenas técnicas numéricas convencionais.

Além da predição de propriedades estáticas, a Inteligência Artificial (IA) é cada vez mais aplicada na modelagem de comportamentos dinâmicos e caóticos. Abordagens híbridas, que combinam análise teórica de sistemas dinâmicos com aprendizado de máquina, têm sido desenvolvidas para prever séries temporais caóticas com maior precisão do que os métodos isolados. A adoção destas técnicas baseadas em dados exige um rigor metodológico na avaliação de desempenho dos modelos gerados. Diferente das simulações determinísticas puras, os modelos de IA devem ser submetidos a métricas estatísticas robustas para validar sua eficácia em relação a modelos existentes ou ao desempenho humano (RAINIO; TEUHO; KLÉN, 2024).

A escolha das métricas de avaliação depende intrinsecamente da natureza da tarefa de simulação. Para tarefas supervisionadas, métricas como acurácia (porcentagem de instâncias corretamente classificadas), *recall* (taxa de verdadeiros positivos), especificidade (taxa de verdadeiros negativos) e precisão (valor preditivo positivo) são comumente empregadas (CHEN et al., 2024). Para tarefas de regressão, onde as saídas são números reais (como a previsão de preços de ações ou precipitação), métricas de erro são fundamentais, como o Erro Absoluto Médio (*Mean Absolute Error* - MAE) e o Erro Quadrático Médio (*Mean Squared Error* - MSE). O MSE é notavelmente sensível, pois penaliza mais os grandes erros do que o MAE. Para garantir a credibilidade do modelo (e de suas métricas), é essencial utilizar testes estatísticos apropriados, como o Teste-T (*t-test*) ou a Análise de Variância (*Analysis of Variance* - ANOVA) (NUNES et al., 2024).

2.2 Ambiente de Simulação de Agentes

Os ambientes de simulação, especialmente os Modelos Baseados em Agentes (MBA), representam um arcabouço robusto para a compreensão e análise de sistemas complexos (ZHANG et al., 2025). Os MBA se concentra em agentes individuais e suas interações dentro de um ambiente, onde os agentes são heterogêneos e dotados de atributos, estados e regras de tomada de decisão distintas. Seus comportamentos se adaptam dinamicamente a fatores ambientais e contextuais, o que leva a fenômenos emergentes em todo o sistema.

Historicamente, os MBA tem sido uma ferramenta inestimável para estudar fenômenos intrincados que são difíceis de observar diretamente no mundo real, facilitando a experimentação, o teste de hipóteses e a análise de cenários em múltiplos domínios. Mais recentemente, as capacidades de reproduzir conhecimento e comportamento semelhantes aos humanos dos LLMs têm gerado grande interesse no uso de agentes com essa tecnologia para mimetizar comportamentos humanóides em várias áreas, incluindo auditorias de sistemas sociais, entretenimento, psicologia e direito (CHEN et al., 2024).

Com a introdução das LLMs, o escopo dos MBA se expandiu dramaticamente, absorvendo novas capacidades e evoluindo para o que é conhecido como MBAG (ADORNETTO et al., 2024). Os AGs são definidos como uma entidades digital que pode simular um comportamento humano verossímil. Esses agentes replicam interações e personalidades semelhantes às humanas, exibem habilidades cognitivas para raciocínio, tomada de decisão e planejamento, e são capazes de executar ações não predefinidas, indo além da racionalidade estrita de modelos tradicionais. (CHEN et al., 2024).

Por outro lado, o uso de LLMs em agentes também acarreta o problema da alucinação, onde um agente pode gerar saídas factualmente incorretas ou infundadas (ADORNETTO et al., 2024). Essas alucinações minam a credibilidade e podem produzir comportamentos incoerentes ou contextualmente irrelevantes. Além da alucinação, os LLMs podem sofrer de inconsistência (ABDULHAI et al., 2024). Por

exemplo, em avaliações morais, eles podem exibir comportamento contraditório e hipócrita quando se comparam valores abstratos (como em questionários) com julgamentos em cenários concretos. Essa inconsistência pode ser exacerbada pela sensibilidade dos LLMs à formulação da pergunta (*prompting*) (SCHERRER et al., 2023), o que levanta a questão de se o modelo mantém um arcabouço moral consistente em diferentes contextos.

O estudo aprofundado dessa inconsistência revela que os agentes generativos falham no teste de coerência moral, sendo caracterizados como hipócritas morais (NUNES et al., 2024). Essa hipocrisia é definida como um conflito entre os valores abstratos declarados (por exemplo, no MFQ) e as avaliações de ações em cenários concretos. Embora modelos de ponta, como o GPT-4 e o Claude 2.1, demonstrem consistência comparável à humana dentro de um único instrumento (MFQ), eles não conseguem manter a coerência entre esses diferentes níveis de abstração. Esse comportamento sugere que os LLMs podem estar engajados em mimetismo moral, reproduzindo padrões linguísticos associados a conceitos morais sem, de fato, possuir o domínio conceitual necessário para aplicar consistentemente seus valores a situações concretas (SIMMONS, 2023).

Além disso, a sensibilidade dos LLMs à formulação da pergunta exige que as avaliações usem múltiplas variações de *prompts* para testar a robustez dos modelos, pois variações na sintaxe da questão podem influenciar fortemente a distribuição de respostas. Experimentos como o de He et al. (2024b) mostram que, em casos em que os LLMs são apresentados a notícias sem um *prompt* que gere uma influência moral, a grande maioria dos trinta e seis modelos testados obteve respostas levemente alinhadas a pessoas liberais nos costumes.

2.3 O que é são os Fundamentos Morais?

A complexidade dos pensamentos humanos e como eles nos levam a tomar determinadas atitudes sempre foi alvo de estudos na área da psicologia e neurociência. Os valores morais são um dos aspectos do enorme quebra-cabeça da racionalidade

humana, além de serem um dos responsáveis por fazer de cada indivíduo uma pessoa única. A Teoria dos Fundamentos Morais foi proposta por Haidt e Joseph (2004), com o objetivo de sintetizar e quantificar os aspectos da moralidade humana.

A primeira proposta apresentava cinco valores morais que estariam presentes em todas as comunidades pelo mundo, independentemente de momento histórico ou cultura, sendo eles Cuidado/Dano, Justiça/Trapaça, Lealdade/Traição, Autoridade/Subversão e Santidade/Degradação. Cuidado, Justiça, Lealdade, Autoridade e Santidade são consideradas virtudes, enquanto seus opostos são chamados de vícios.

- **Cuidado/Dano (*Care/Harm*):** Este fundamento refere-se à evolução de mecanismos psicológicos para a proteção e cuidado de descendentes vulneráveis. Manifesta-se como uma sensibilidade aguçada a sinais de sofrimento e necessidade em outros, gerando intuições morais que condenam o dano e valorizam a compaixão. As virtudes associadas incluem a gentileza e o altruísmo, enquanto os vícios correspondentes são a crueldade e a agressão.
- **Justiça/Trapaça (*Fairness/Cheating*):** Originado do desafio adaptativo do altruísmo recíproco, este fundamento governa as intuições sobre justiça distributiva e procedural. Ele monitora a proporcionalidade entre contribuições e resultados em interações sociais, gerando reações negativas à trapaça e ao favorecimento indevido. As virtudes centrais são a justiça, a honestidade e a confiabilidade, com uma forte motivação para a aplicação de punição a transgressores.
- **Lealdade/Traição (*Loyalty/Betrayal*):** Derivado da longa história de competição intergrupar da espécie humana, este fundamento sustenta a formação e manutenção de coalizões coesas. Ele promove virtudes como o patriotismo, o sacrifício pelo grupo e a vigilância contra a traição. As intuições de lealdade são ativadas por símbolos e marcadores de pertencimento grupal.
- **Autoridade/Subversão (*Authority/Subversion*):** Este fundamento emerge da necessidade de navegar e manter hierarquias sociais estáveis e benéficas. Ele gera intuições sobre respeito, deferência a autoridades legítimas e a importância

de tradições. As virtudes associadas são a obediência e a liderança, enquanto a subversão e a desordem são percebidas como ameaças morais à estabilidade social.

- **Santidade/Degradação (*Sanctity/Degradation*):** Com raízes evolutivas no sistema imunológico comportamental e na emoção do nojo para evitar patógenos, este fundamento foi cooptado para o domínio simbólico. Ele sustenta a noção de que certas coisas são sagradas e intocáveis, devendo ser protegidas da profanação e da degradação. Gera intuições sobre pureza, ascetismo e a elevação espiritual, em oposição à contaminação e à degradação moral.

Com o passar dos anos, o tema foi sendo melhor explorado por pesquisadores em busca de usá-los para entender melhor o comportamento humano. A partir de pesquisas, foi percebido um padrão em que pessoas que se identificam como liberais têm uma tendência maior a expressar os fundamentos da Justiça e do Cuidado, enquanto pessoas que se identificam como conservadoras tendem a expressar os cinco fundamentos de maneira muito mais equilibrada entre si (GRAHAM; HAIDT; NOSEK, 2009).

Outro tópico muito debatido em cima dessa teoria, é se somente essas cinco virtudes são capazes de explicar toda a complexidade da moral em seus diferentes contextos culturais e sociais, por isso foram propostas diferentes adições e modificações a esse grupo visando representar melhor o pensamento de diferentes indivíduos. O fundamento da Justiça pode ter um significado amplo, visto que o senso de justiça de cada pessoa pode variar bastante baseado em suas vivências e crenças. Uma forma de resolver esse problema é a divisão desse fundamento em Igualdade, que geralmente tem uma maior relação com pessoas com posicionamentos mais à esquerda politicamente, e Proporcionalidade, que tem mais identificação com pessoas mais inclinadas a posicionamentos mais à direita (ATARI; HAIDT, 2023).

Diferentes virtudes foram consideradas e sugeridas para fazer parte desse grupo, mas para isso foram estabelecidas regras do que pode ser considerado um fundamento moral (GRAHAM et al., 2013). As candidatas devem seguir as seguintes exigências:

- Ser uma característica comum em juízos de valor imparciais (feitos por terceiros);
- Estar ligado a reações emocionais automáticas;
- Possuir ampla disseminação cultural, mesmo que não seja universalmente encontrado;
- Apresentar evidências de uma predisposição inata;
- Ser sustentado por um modelo evolucionário robusto e já existente.

Com esses pré-requisitos alguns candidatos foram propostos, como a Propriedade(ATARI; HAIDT, 2023), que está presente no comportamento humano desde o início da vida em sociedade e que pode ser observado inclusive em animais. A honra é outro candidato muito forte, principalmente pela sua importância em povos e culturas no Oriente Médio e em como ela trata de temas como reputação familiar e orgulho, tópicos que os outros fundamentos não cobrem por completo.

2.4 Como ocorre a difusão de informações nas redes sociais?

As redes sociais revolucionaram a forma como as pessoas se comunicam e como informações e notícias circulam pelo mundo. Essas plataformas não apenas difundem um volume extraordinário de conteúdo, sendo amplamente utilizadas pelos meios de comunicação tradicionais, como também reduziram as barreiras para a produção de notícias e tornaram mais tênue a fronteira entre veículos de imprensa e usuários comuns (ZHENG et al., 2018). Esse novo modo de propagar as informações tem grande impacto em diversas áreas, desde a publicidade segmentada e sistemas de recomendação de produtos, até à propaganda política e redes de opinião pública.

A velocidade e o alcance da propagação de mensagens nas redes sociais são influenciados por diversos fatores, sendo a qualidade do conteúdo e a reação emocional dos usuários os dois principais. Zheng et al. (2018) concluiu que o conteúdo da mensagem é um fator de disseminação mais forte do que a popularidade do remetente. Esta qualidade do conteúdo, refletida na probabilidade de compartilhamento,

2.5 A influência da moralidade na difusão de informações nas redes sociais

tem um limiar que afeta a sua capacidade de propagação: se a probabilidade de reencaminhamento estiver acima desse limiar, a mensagem alcança rapidamente a disseminação em massa, resultando em um fenômeno de transição de fase onde as mensagens tendem a ser amplamente visualizadas ou quase inteiramente ignoradas.

Surjatmodjo et al. (2024) constatou que notícias falsas no Twitter se propagam seis vezes mais rápido do que notícias reais e alcançam mais pessoas. A disseminação viral é impulsionada pela utilização da emoção. Conteúdo que desencadeia emoções fortes, especialmente raiva e medo, tem maior probabilidade de ser compartilhado. Conteúdo moralizado temperado com emoção demonstrou ser mais viral em redes sociais, quando notícias duvidosas são apresentadas de uma forma que é coerente com as preferências existentes baseadas em valores, a comunidade as aceita mais facilmente e promove sua propagação através da partilha seletiva(IANDOLI SIMONETTA PRIMARIO, 2021). O discurso emocional é ativamente favorecido pelas redes sociais, o que facilita a argumentação polarizada.

A internet é um ambiente propenso à polarização. A Polarização de Grupo é uma dinâmica disfuncional na qual os participantes se tornam mais extremos na sua posição inicial após serem expostos a uma discussão. Isso pode ser o resultado de homofilia, a tendência de interagir socialmente com indivíduos semelhantes, o que leva à formação de bolhas de informação, ou câmaras de eco, (IANDOLI SIMONETTA PRIMARIO, 2021). Essas câmaras de eco reforçam crenças preexistentes e a polarização política. A polarização também pode ser produzida pela exposição à diversidade, como quando facções opostas se confrontam para avançar a sua própria agenda (argumentação discursiva), reforçando a afiliação *in-group* e *out-group*(TALAMANCA; ARFINI, 2022).

2.5 A influência da moralidade na difusão de informações nas redes sociais

Como apresentado anteriormente, diversos fatores influenciam a decisão de um usuário quanto ao compartilhamento de publicações em redes sociais. Entre esses

2.5 A influência da moralidade na difusão de informações nas redes sociais

fatores, destaca-se a moralidade do indivíduo e o enquadramento moral presente na mensagem da publicação. Nesse contexto, a MFT é frequentemente utilizada para quantificar a moralidade de indivíduos e de conteúdos, permitindo a identificação de padrões de comportamento, como quais fundamentos morais estão associados a uma maior propensão ao compartilhamento e quais perfis morais de usuários apresentam maior probabilidade de compartilhar determinados tipos de conteúdo.

No artigo (BRADY et al., 2017), os autores analisaram um dataset com mais de 560.000 publicações na plataforma Twitter, relacionadas a temas políticos polarizadores, como controle de armas, casamento homoafetivo e mudanças climáticas. Para a medir do conteúdo moral e emocional de cada publicação, foram utilizados dicionários validados que permitem identificar a frequência de termos classificados como morais, emocionais e moral-emocionais (TAUSCZIK; PENNEBAKER, 2010). A partir desses dados, foram aplicados modelos de regressão com o objetivo de estimar o impacto dessas categorias na taxa de compartilhamento das publicações, medida por meio de *retweets*. Os resultados indicam que a presença de linguagem moral-emocional está associada ao aumento na difusão das mensagens. Além disso, observa-se que esse efeito ocorre de forma mais intensa em interações entre indivíduos com alinhamento ideológico semelhante, sugerindo que a difusão de conteúdo moral está condicionada à estrutura de grupos nas redes sociais.

O estudo de (SAKELLARIOU; TRILLING; SCHOENBACH, 2023) investiga a relação entre valores pessoais, conteúdo moral e compartilhamento de notícias enganosas em ambientes online. O experimento consistiu em um estudo quase-experimental com 132 participantes, nos quais os usuários foram expostos a capturas de tela de notícias enganosas que ativavam os cinco domínios da MFT, apresentadas com diferentes níveis de viés comunicativo. Após a exposição, os participantes responderam a questionários que mensuravam valores pessoais, percepção de credibilidade, respostas emocionais e intenção de compartilhamento. Os dados foram analisados por meio de Modelagem de Equações Estruturais, com o objetivo de identificar relações entre essas variáveis.

Os resultados indicaram que indivíduos conservadores apresentam maior propen-

são ao compartilhamento de notícias enganosas, liberais estão associados à redução desse comportamento. Além disso, a percepção de credibilidade, em conjunto com a ativação emocional, possui influencia direta na decisão de compartilhamento (SAKELLARIOU; TRILLING; SCHOENBACH, 2023).

Outro experimento que também buscava entender a probabilidade de compartilhamento de notícias falsas foi o (HE et al., 2024a), nele foi investigada a relação entre enquadramentos baseados na MFT e o compartilhamento de desinformação e mensagens corretivas sobre vacinas contra a COVID-19. O experimento foi conduzido com participantes expostos a conteúdos estruturados com diferentes enquadramentos morais, cada um associado a fundamentos específicos da MFT. Após a exposição, os participantes avaliaram a credibilidade das mensagens e indicaram sua intenção de compartilhamento, permitindo a análise do efeito dos enquadramentos morais no comportamento de difusão.

Os resultados indicaram que os fundamentos morais exercem papel central na decisão de compartilhamento. Observa-se que mensagens enquadradas de acordo com fundamentos morais específicos apresentam maior probabilidade de serem compartilhadas quando há alinhamento com o perfil moral do indivíduo. Esse efeito ocorre tanto para desinformação quanto para mensagens verídicas, indicando que a ativação de fundamentos morais influencia a difusão independentemente da veracidade do conteúdo (HE et al., 2024a). Além disso, a percepção de credibilidade atua em conjunto com o enquadramento moral, mas os resultados indicam que o alinhamento moral é um dos principais fatores associados ao comportamento de compartilhamento.

2.6 Concordia

Concordia é uma biblioteca que foi desenvolvida para facilitar a construção e o trabalho com MBAG em simulações sociais (VEZHNEVETS et al., 2023). Os agentes generativos no Concordia utilizam LLMs para aplicar senso comum às situações, agir de maneira coerente ao comportamento humano, recordar conhecimento semântico e realizar chamadas de Application Programming Interface (API) para

controlar tecnologias digitais. Ao contrário dos MBAs tradicionais, os MBAGs não se limitam apenas a agentes que conversam; eles são construídos para simular interações complexas de agentes em ambientes fundamentados, sejam físicos, sociais ou digitais.

A arquitetura do Concordia emprega um padrão de interação inspirado em jogos de RPG de mesa (role-playing games), onde a simulação é mediada por um agente especializado: o GM (VEZHNEVETS et al., 2023). O GM é responsável por simular o ambiente e o contexto das interações sociais. Os agentes expressam suas ações descrevendo o que pretendem fazer em linguagem natural, e o GM traduz essas descrições para implementações apropriadas. Em simulações de um mundo físico, o GM verifica a plausibilidade física das ações. Em ambientes digitais, o GM pode gerenciar chamadas de API para integrar-se a ferramentas externas, como assistentes de IA gerais ou aplicativos digitais. Essa flexibilidade permite que o GM utilize qualquer técnica de modelagem existente para simular as partes não linguísticas da simulação, como fenômenos físicos, químicos ou financeiros.

A funcionalidade do agente individual no Concordia é modular, inspirada em trabalhos anteriores, como Park et al. (2023). Os agentes produzem seu comportamento utilizando um sistema flexível de componentes que faz o intermédio entre as chamadas ao LLM e a recuperação de memória associativa. Esses componentes representam a "sociedade da mente" do agente, focando em aspectos relevantes como estado fisiológico ou circunstâncias financeiras, para gerar o texto de condicionamento. O agente possui uma memória de longo prazo, associativa, para registrar suas experiências históricas, e uma memória de trabalho que contém o contexto imediato para a previsão do próximo símbolo. O processo de tomada de decisão, que é uma amostragem autorregressiva condicionada ao contexto, é guiado pela "lógica da adequação" (MARCH; OLSEN, 2011), que sugere que as pessoas escolhem suas ações respondendo a três perguntas-chave:

1. Que tipo de situação é esta?
2. Que tipo de pessoa sou eu?
3. O que uma pessoa como eu faz em uma situação como esta?

O GM inicia sua função gerando uma declaração de evento e_t em resposta a cada ação a_t tentada por um agente. A geração desta declaração é um processo estocástico que utiliza uma LLM (p) e é condicionada pelo estado interno atual do GM (representado pelos seus componentes z_t) e pela ação do agente. Formalmente, isso é representado pela Equação (3):

$$e_t \sim p(\cdot \mid f_e(z_t), a_t) \quad (2.1)$$

Nesta formulação, a_t é a ação submetida pelo agente (descrita em linguagem natural, por exemplo, “Dorothy vai ao supermercado”). A função f_e formata o estado dos componentes do GM (que descrevem o estado do mundo, como a localização dos jogadores e o status das variáveis fundamentadas) para servir como contexto na consulta ao LLM p . O ato de condicionar explicitamente na ação a_t serve para enfatizar que o GM gera uma declaração de evento em resposta a cada ação de qualquer agente na simulação. Isso é uma distinção importante, pois um agente pode receber várias observações antes de decidir agir (VEZHNEVETS et al., 2023). Após a geração, a declaração de evento e_t é adicionada à memória associativa do GM para registrar o que aconteceu.

Após registrar o evento e_t em sua memória, o GM atualiza seus próprios componentes internos, seguindo a mesma lógica de atualização dos agentes. O GM, assim como os agentes generativos, é implementado usando componentes que intermediam as chamadas ao LLM e a recuperação da memória. O processo de atualização do GM (similar à Equação (2) do agente) utiliza o LLM para sumarizar e raciocinar, garantindo que o estado interno do GM reflita as novas informações contidas no evento e_t . Depois desta atualização interna, o GM pode emitir observações $o_{i,t+1}$ para os jogadores. A emissão de observações para um jogador i é regida pela Equação (4):

$$o_{i,t+1} \sim p(\cdot \mid f_o(z_{t+1})) \quad (2.2)$$

Aqui, f_o é uma função de formatação que usa o estado atualizado dos componentes

do GM (z_{t+1}) para gerar a observação em linguagem natural. É crucial notar que o GM só emite uma observação se ele julgar que o jogador em questão realmente observou o evento. Em outras palavras, o GM gerencia a percepção parcial do ambiente por parte dos agentes.

Devido a essas funcionalidades, o Concordia se torna uma das melhores opções de biblioteca/*framework* para a construção de experimentos usando ambientes de simulação de agentes generativos, principalmente focados em fenômenos provenientes de relações sociais, sejam elas presenciais ou digitais.

Capítulo 3

Metodologia

Este capítulo apresenta o conjunto de dados que foi utilizado para o experimento, como ele foi formado, a metodologia utilizada para efetuar a simulação e os resultados encontrados.

3.1 Dataset

O conjunto de dados escolhido consiste em uma base de 30 personas, com diferentes personalidades, vivências e moralidades, visando simular uma sociedade composta por pensamentos diversos e plurais. As personas foram selecionadas a partir do *dataset* Persona Hub (GE et al., 2025). Este, por sua vez, foi criado a partir de textos coletados de diversos sites na internet, como fóruns, *blogs* e redes sociais. Esses textos foram fornecidos a um LLM com o objetivo de extrair personas explícitas presentes nos conteúdos ou gerar novas personas com base nas informações descritas.

O *dataset* contém aproximadamente um bilhão de personas, entretanto, as quarenta selecionadas neste trabalho buscam representar, de forma fiel, diferentes perfis de usuários de redes sociais no Brasil, ao mesmo tempo que apresenta diferentes padrões moralidade, como é possível analisar na Figura 3.1.

Para garantir maior consistência na interpretação das personas por parte dos LLMs e aprofundar sua representação, foi adotada uma abordagem estruturada




Figura 3.1: Agrupamento moral das personas por K-Means e PCA

de enriquecimento de atributos. Com o apoio do ChatGPT-5, cada persona foi descrita por um conjunto padronizado de características, incluindo nome, faixa etária, profissão, localização, nível educacional, interesses, crenças e uma breve descrição contextual.

Essa formalização permitiu reduzir ambiguidades e variabilidade nas respostas geradas, tornando as personas mais distintas e semanticamente consistentes. Como resultado, observou-se maior estabilidade na reprodução dos comportamentos simulados ao longo de diferentes execuções, contribuindo para a confiabilidade dos experimentos.

Com o objetivo de melhor entender a moralidade de cada persona, elas foram expostas ao MFQ30. Foi utilizado o LLM Deepseek:32b para interpretar cada persona, e assim responder às 32 perguntas do questionário. Os resultados foram usadas para confirmar a pluralidade moral do *dataset* escolhido, e para ajudar a contextualizar e aprofundar a interpretação de cada persona por parte do Concordia, a moralidade obtida para cada persona pode ser observada na Figura 3.2.




Figura 3.2: Intensidade dos Fundamentos Morais por Persona

3.2 Experimento

Para o ambiente de simulação, foi usada uma configuração de GM que simula uma rede social no formato de um fórum assíncrono. Com esse GM, os agentes interagem com o fórum concorrentemente em *multi threads*. Assim, cada agente permanece em um ciclo solicitando o estado atual do fórum ao GM e, com base nas últimas publicações do fórum, o LLM decide se executará uma ação e qual ela será.

Diferentemente dos GM tradicionais, o GM de rede social não tira conclusões próprias ou instiga pensamentos nos demais agentes. Sua principal função é registrar as publicações e as ações tomadas por cada agente, organizá-las e apresentá-las aos demais agentes, adotando uma postura mais passiva. Outro ponto importante deste GM é que ele não utiliza LLM, ele espera que os agentes respondam às ações em um formato JSON predefinido. Assim, de forma determinística, o sistema utiliza regex para processar e registrar as ações no *feed* do fórum.

Para os experimentos, o grupo de 40 personas foi dividido aleatoriamente em grupos menores de 5 personas a cada teste, visando proporcionar diferentes combinações de grupos, com baixas e altas similaridades. Cada agente possuía 6 ações possíveis ao visualizar o *feed* do fórum: postar uma nova publicação, responder a uma publicação presente no fórum, dar *upvote* ou *downvote*, compartilhar a publicação, ou apenas ignorar.

A geração do debate baseou-se em um conjunto de notícias fictícias, elaboradas para ativar diferentes fundamentos morais e apresentar variados graus de controvérsia (e.g., corrupção, casamento homoafetivo e crise climática). A cada experimento, uma das notícias era selecionada aleatoriamente e inserida previamente, em formato de publicação, na memória de cada agente. Desse modo, ao iniciar a simulação, todos os agentes já começavam debatendo e interagindo com a publicação original.

Outra variável adicionada aos experimentos foi a utilização de diferentes nomes para o fórum: um neutro, denominado "Rural News"; um alinhado à moralidade conservadora, "Voz Conservadora"; e um alinhado ao liberalismo nos costumes, "Voz Progressista". O título do fórum era definido previamente e de forma aleatória, com o intuito de analisar o comportamento de cada persona em diferentes ambientes, independentemente de estarem ou não alinhados com sua visão.

Capítulo 4

Resultados

Esta seção apresenta uma análise da influência dos fundamentos morais sobre a difusão de informações, análises detalhadas das interações obtidas pelos agentes autônomos no ambiente de simulação Concordia, e um comparativo do engajamento gerado frente a diferentes cenários de notícias e alinhamentos ideológicos dos fóruns.

4.1 Análise

A partir dos relatórios produzidos pelo Concordia, pode-se perceber uma grande capacidade por parte do Deepseek-8b de reproduzir o comportamento esperado pelas personas interpretadas. Os agentes constantemente agem de acordo com o esperado não só a partir de suas descrições, mas principalmente com base nos fundamentos morais. Foi possível perceber certos padrões comuns em experimentos que utilizam a MFT com seres humanos, como, por exemplo, personas que possuíam como destaque os valores morais do cuidado e da igualdade adotando um posicionamento relacionado a indivíduos liberais nos costumes, enquanto personas que apresentavam os cinco fundamentos de maneira equilibrada geralmente agiam como pessoas mais conservadoras (GRAHAM; HAIDT; NOSEK, 2009).

O uso de diferentes nomes para os fóruns surtiu pouca influência no comportamento dos agentes, porém, em experimentos específicos, pôde-se perceber que

alguns agentes que não possuíam de forma clara seu posicionamento político nem em sua descrição, nem uma pontuação de MFT muito extrema para algum dos lados políticos, acabavam adotando um posicionamento com base no nome do fórum e na opinião dos demais agentes que discutiam no fórum.

Apesar desses momentos em que os agentes utilizaram o nome do fórum ou os demais agentes como base para formar sua opinião, o comportamento mais comum observado foi o de agentes que não possuíam um posicionamento político claro optarem por seguir uma postura levemente mais alinhada ao liberalismo nos costumes, o que vai ao encontro da pesquisa de He et al. (2024b), a qual, apesar de não ter realizado experimentos usando o Deepseek-8b, obteve um resultado semelhante em seu experimento com outros modelos. Esses agentes tendiam a não participar ativamente das discussões; apenas emitiam opiniões simples e tendiam a dar *upvotes* nas publicações favoráveis à sua opinião.

Outro ponto identificado foi como a notícia principal influencia a difusão e o engajamento. Quando a notícia era de consenso geral ou não apresentava uma opinião forte, como notícias relacionadas a doações para hospitais infantis e crise climática, ela tendia a receber menos *upvotes* e compartilhamentos. Nesses casos, os agentes tendiam a fazer comentários de apoio, reiterando a mensagem apresentada na notícia e em novas publicações relacionadas. Por outro lado, notícias acerca de temas polêmicos tendiam a ter uma quantidade maior de *upvotes* e *downvotes*, assim como um maior número de compartilhamentos, não só da notícia principal, mas também de comentários sobre ela, fossem eles contrários ou a favor.

Capítulo 5

Conclusões

5.1 Problema

A sociedade contemporânea está imersa em um ecossistema de informação digital complexo e de alta velocidade. O advento das redes sociais como principais intermediárias da informação alterou fundamentalmente a forma como notícias, opiniões e narrativas são criadas, consumidas e compartilhadas. Neste cenário, a informação propaga-se em escala global e em tempo real, conectando bilhões de indivíduos.

Informações factualmente incorretas, enganosas ou deliberadamente falsas, comumente categorizadas como desinformação, demonstram uma capacidade de propagação viral equivalente, e por vezes superior, à de conteúdos verificados e factuais. Como resultado, a propagação da informação é mediada menos pela sua precisão e mais pela sua capacidade de ressoar com as afinidades de um determinado grupo. Isso fomenta a criação de bolhas informacionais e câmaras de eco, onde narrativas concorrentes coexistem sem um debate público saudável. As consequências dessa dinâmica são vastas e socialmente relevantes, incluindo a erosão da confiança pública, a intensificação da polarização social e política, e a distorção da percepção da realidade.

5.2 Proposta

5.3 Resumo dos resultados

TODO

5.4 Contribuições

TODO

5.5 Direções Futuras

TODO

Referências

ABDULHAI, M. et al. Moral foundations of large language models. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. [S.l.]: Association for Computational Linguistics, 2024. p. 17737–17752.

ADORNETTO, C. et al. Generative agents in agent-based modeling: Overview, validation, and emerging challenges. *arXiv preprint arXiv:2405.18432*, 2024.

ATARI, M.; HAIDT, J. Ownership is (likely to be) a moral foundation. *Behavioral and Brain Sciences*, v. 46, p. e326, 2023.

BADARINATH, V.; CHIERICHETTI, R.; KAKHKI, F. D. A machine learning approach as a surrogate for a finite element analysis: Status of research and application to one dimensional systems. *Sensors*, v. 21, n. 5, p. 1654, 2021. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC7957535/>>.

BANKS, J. et al. *Discrete-Event System Simulation*. 5th. ed. Upper Saddle River, NJ: Pearson, 2010.

BRADY, W. J. et al. Emotion shapes the diffusion of moralized content in social networks. *Proceedings of the National Academy of Sciences*, v. 114, n. 28, p. 7313–7318, 2017.

CHEN, C. et al. Evaluating the LLM agents for simulating humanoid behavior. In: *1st HEAL Workshop at CHI Conference on Human Factors in Computing Systems*. Honolulu, HI, USA: [s.n.], 2024.

CHUANG, Y.-S. et al. Simulating opinion dynamics with networks of LLM-based agents. *arXiv preprint arXiv:2311.09618*, 2023.

GE, T. et al. *Scaling Synthetic Data Creation with 1,000,000,000 Personas*. 2025. Disponível em: <<https://arxiv.org/abs/2406.20094>>.

GRAHAM, J. et al. Moral foundations theory: The pragmatic validity of moral pluralism. In: DEVINE, P.; PLANT, A. (Ed.). *Advances in Experimental Social Psychology*. Academic Press, 2013. v. 47, p. 55–130. ISBN 9780124072367. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780124072367000024>>.

GRAHAM, J.; HAIDT, J.; NOSEK, B. A. Liberals and conservatives rely on different sets of moral foundations. *Journal of Personality and Social Psychology*, American Psychological Association, v. 96, n. 5, p. 1029–1046, 2009.

- GUO, S.; MOKHBERIAN, N.; LERMAN, K. A data fusion framework for multi-domain morality learning. In: *Proceedings of the Seventeenth International AAAI Conference on Web and Social Media, ICWSM 2023*. [S.l.]: Association for the Advancement of Artificial Intelligence, 2023. p. 281–291.
- HAIDT, J.; JOSEPH, C. Intuitive ethics: How innately prepared intuitions generate culturally variable virtues. *Daedalus*, v. 133, n. 4, p. 55–66, 2004.
- HE, Y. et al. Sharing is caring? how moral foundation frames drive the sharing of corrective messages and misinformation about covid-19 vaccines. *Humanities and Social Sciences Communications*, v. 11, n. 1, p. 320, 2024.
- HE, Z. et al. Whose emotions and moral sentiments do language models reflect? In: *Findings of the Association for Computational Linguistics: ACL 2024*. Bangkok, Thailand: Association for Computational Linguistics, 2024. p. 6611–6631. Disponível em: <<https://aclanthology.org/2024.findings-acl.395/>>.
- LANDOLI SIMONETTA PRIMARIO, G. Z. L. The impact of group polarization on the quality of online debate in social media: A systematic literature review. *Technological Forecasting and Social Change*, 2021.
- KRZYWAŃSKI, J. et al. Advanced computational methods for modeling, prediction and optimization—a review. *Materials*, MDPI, v. 17, n. 14, p. 3521, 2024. Disponível em: <<https://www.mdpi.com/1996-1944/17/14/3521>>.
- MARCH, J. G.; OLSEN, J. P. The logic of appropriateness. In: GOODIN, R. E. et al. (Ed.). *The Oxford Handbook of Political Science*. Oxford University Press, 2011. p. 12. Disponível em: <<https://academic.oup.com/edited-volume/35474/chapter/303820733>>.
- NUNES, J. L. et al. Are large language models moral hypocrites? a study based on moral foundations. In: *Proceedings of the Seventh AAAI/ACM Conference on AI, Ethics, and Society (AIES-24)*. [S.l.]: AAAI Press, 2024. p. 1074–1087. Published by the Association for the Advancement of Artificial Intelligence (www.aaai.org) [1, 2].
- PARK, J. S. et al. Generative agents: Interactive simulacra of human behavior. *arXiv preprint arXiv:2304.03442*, 2023. Revised version as of 6 Aug 2023. Disponível em: <<https://arxiv.org/abs/2304.03442>>.
- RAHMAN, A. et al. Surrogate model for cfd based on machine learning. In: VAZE, J. et al. (Ed.). *MODSIM2023: 25th International Congress on Modelling and Simulation*. Darwin, NT, Australia: Modelling and Simulation Society of Australia and New Zealand Inc., 2023. Disponível em: <<https://www.mssanz.org.au/modsim2023/files/rahman37.pdf>>.
- RAINIO, O.; TEUHO, J.; KLÉN, R. Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, Nature Portfolio, v. 14, n. 1, p. 6086, 2024. Disponível em: <<https://www.nature.com/articles/s41598-024-56706-x>>.

SAKELLARIOU, K.; TRILLING, D.; SCHOENBACH, K. How personal values count in misleading news sharing with moral content. *Social Network Analysis and Mining*, v. 13, n. 1, p. 27, 2023.

SCHERRER, N. et al. Evaluating the moral beliefs encoded in LLMs. In: *37th Conference on Neural Information Processing Systems (NeurIPS 2023)*. [S.l.: s.n.], 2023. Equal Contribution.

SIMMONS, G. Moral mimicry: Large language models produce moral rationalizations tailored to political identity. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 4: Student Research Workshop)*. Toronto, Canada: Association for Computational Linguistics, 2023. p. 282–297.

SURJATMODJO, D. et al. Information pandemic: A critical review of disinformation spread on social media and its implications for state resilience. *Social Sciences*, v. 13, n. 8, p. 418, 2024. ISSN 2076-0760.

TALAMANCA, G. F.; ARFINI, S. Through the newsfeed glass: Rethinking filter bubbles and echo chambers. *Philosophy & Technology*, v. 35, n. 1, p. 20, 2022.

TAUSCZIK, Y. R.; PENNEBAKER, J. W. The psychological meaning of words: Liwc and computerized text analysis methods. *Journal of Language and Social Psychology*, v. 29, n. 1, p. 24–54, 2010.

VEZHNEVETS, A. S. et al. Generative agent-based modeling with actions grounded in physical, social, or digital space using Concordia. *arXiv preprint arXiv:2312.03664*, 2023.

ZHANG, L. et al. LLM-AIDSim: LLM-enhanced agent-based influence diffusion simulation in social networks. *Systems*, v. 13, n. 1, p. 29, 2025.

ZHENG, Z. et al. Factors influencing message dissemination through social media. *Phys. Rev. E*, American Physical Society, v. 97, p. 062306, Jun 2018. Disponível em: <<https://link.aps.org/doi/10.1103/PhysRevE.97.062306>>.